

Ce document de test decrit en detail le fonctionnement du systeme de recherche vectorielle utilise par Vector pour repondre aux questions des utilisateurs sur leurs corpus de documents. Le systeme utilise des embeddings de dimension 1536 generes par le modele text-embedding-3-small, indexes dans une base PostgreSQL grace a l'extension pgvector. La recherche se fait par similarite cosinus entre le vecteur de la question et les vecteurs des fragments de texte extraits des documents sources, avec un mecanisme de diversite qui garantit que chaque document du corpus soit represente dans les resultats retournes.